

Retail Decision Agent

零售经营决策系统 · 产品白皮书

版本 V1.0

2026 年 9 月 30 日

在线预览: <https://shenyuanyuan77.github.io/retail-decision-agent/>

代码仓库: <https://github.com/shenyuanyuan77/retail-decision-agent>

功能目录

第一篇 产品概述

1 产品定位与核心价值 / 2 系统架构 / 3 核心能力总览（R1-R5）

第二篇 核心功能详解

4 经营总览 / 5 异常中心：自动发现 / 6 根因分析 / 7 补货与促销建议 / 8 授权执行与审批 / 9 执行记录与审计

第三篇 治理与安全

10 权限矩阵与策略引擎 / 11 写操作四保险

第四篇 部署与使用

12 快速启动 / 13 在线预览与版本迭代 / 14 验收结果 / 15 常见问题

目录

第一篇 产品概述.....	3
1 产品定位与核心价值.....	3
2 系统架构.....	4
3 核心能力总览.....	5
第二篇 核心功能详解.....	5
4 经营总览.....	5
5 异常中心：自动发现.....	5
5.1 检测算法.....	6
5.2 异常列表.....	6
6 根因分析.....	6
7 补货与促销建议.....	7
8 授权执行与审批.....	7

9 执行记录与审计..... 8

第三篇 治理与安全..... 8

10 权限矩阵与策略引擎..... 9

11 写操作四保险..... 9

第四篇 部署与使用..... 10

12 快速启动..... 10

13 在线预览与版本迭代..... 10

14 验收结果..... 11

15 常见问题..... 11

注：本目录由域代码生成。编辑文档后请右键目录选择“更新域”以刷新页码。

第一篇 产品概述

1 产品定位与核心价值

零售经营决策 Agent（Retail Decision Agent）面向全国连锁零售企业，接入门店、会员、供应链、客服等多个业务系统，以一条完整闭环工作流替代人工巡检与经验决策：

- **自动发现**系统持续扫描销售数据，自动发现销量异常，无需人工发起；
- **根因分析**对每个异常自动进行多维度假设验证，输出带证据链与置信度的根因 Top3；
- **建议生成**按根因匹配打法库，生成补货或促销建议，含约束检查与成本收益估算；
- **授权执行**低风险动作自动执行，高风险动作强制转人工审批，全程留痕可审计。

与传统数据看板的本质区别在于：看板回答“发生了什么”，本产品回答“为什么发生、该怎么办、办了之后效果如何”，并把每一步交给可控可审计的 Agent 执行。

2 系统架构

系统采用“单体服务、分域设计”架构：六大业务系统作为事实数据源，四个 Agent 层完成发现到执行的推理链路，治理层贯穿所有写入路径：

表 2-1 系统分层架构

层	模块	职责	技术
业务系统层	services/（6个）	主数据 / 销售 / 库存供应链 / 会员 / 客服 / 外部数据，提供事实与执行通道	FastAPI REST + OpenAPI
感知层	agents/perception	滚动中位数 + MAD + z-score 统计检测，主动发现销量异常	纯 Python 算法
诊断层	agents/diagnosis	9 类假设验证，输出根因 Top3 + 置信度 + 证据链	假设验证框架

层	模块	职责	技术
决策层	agents/decision	根因 × 打法库 → 补货/促销建议，约束检查 + ROI 估算	YAML 知识库
执行层	agents/execution	六大写工具，状态机管理，失败可补偿	幂等 + 补偿
治理层	governance/	权限矩阵 L0-L4、策略引擎、审批、审计、干线写入	Policy Engine
前端	web/	经营控制台（6 核心页面）	浅色主题，无构建 SPA

大模型在系统中只承担“叙述解释”职责：所有数字均来自工具返回的事实数据，并内置防编造校验（叙述中出现事实表之外的数字即自动回退模板叙述）从机制上保证结论可追溯。已用 DeepSeek 真实模型实测验证。

3 核心能力总览

表 3-1 核心能力与实现方式（R1-R5）

编号	能力	实现方式	验证结果
R1	多系统接入	6 大 Mock 业务系统，只读工具层统一接入	接口实测全部返回真实数据
R2	自动发现异常	统计检测主动扫描，支持定时调度	3 类注入异常召回率 100%
R3	分析原因	9 类假设验证，每根因至少 2 条证据	根因 Top3 命中率 100%
R4	补货/促销建议	根因×打法库，MOQ/毛利/预算约束 + ROI	约束违反率 0
R5	授权范围内执行	L0-L4 权限 + 策略引擎 + 人工审批	高风险审批合规率 100%

第二篇 核心功能详解

4 经营总览

控制台首页呈现全局经营态势：近 7 天销售额与环比、销量、毛利率、待处理异常与待审批计数一目了然，并提供 30 天销售趋势与门店排行。右上角“运行 Agent”按钮一键完成发现异常→原因分析→生成建议→执行全流程。




图 4-1 经营总览：KPI、趋势与最新异常

5 异常中心：自动发现

5.1 检测算法

感知层以传统统计算法而非大模型猜测发现异常：先用前 28 天滚动中位数与 MAD 建立基线，再对近 14 天逐日计算 z-score 与偏差比例，连续 2 天以上偏离即识别为异常段；另设客诉激增、库存归零等业务规则。每个异常均携带观察值、期望值、偏差、严重度与数据证据。

5.2 异常列表

产品类	类型	门店	商品	现值 / 期望	偏差	时间窗口	状态
critical	销量下降	上海001店	P00037	0 / 3	-100%	09-29 ~ 09-30	diagnosed
critical	销量下降	杭州002店	P00016	0 / 3	-100%	09-22 ~ 09-23	diagnosed
critical	销量下降	深圳007店	P00003	0.25 / 10	-97.5%	09-19 ~ 09-30	decided
critical	销量下降	上海001店	P00032	0.5 / 3	-83.3%	09-20 ~ 09-22	diagnosed
critical	销量下降	南京003店	P00032	0.5 / 3	-83.3%	09-23 ~ 09-24	diagnosed
high	销量下降	天津003店	P00025	0.67 / 3	-77.8%	09-28 ~ 09-30	diagnosed
high	销量下降	上海001店	P00025	1.25 / 4.5	-72.2%	09-21 ~ 09-24	diagnosed
high	销量下降	杭州002店	P00025	1.5 / 5	-70%	09-22 ~ 09-23	diagnosed
high	销量下降	上海001店	P00031	1 / 3	-66.7%	09-23 ~ 09-24	diagnosed
high	销量下降	杭州002店	P00008	1 / 3	-66.7%	09-22 ~ 09-24	diagnosed
high	销量下降	杭州002店	P00019	1 / 3	-66.7%	09-27 ~ 09-28	diagnosed
high	销量下降	南京003店	P00035	1 / 3	-66.7%	09-21 ~ 09-23	diagnosed
high	销量下降	长沙011店	P00017	1 / 3	-66.7%	09-19 ~ 09-21	diagnosed
high	销量下降	北京004店	P00027	3.67 / 9.5	-61.4%	09-20 ~ 09-25	decided
medium	销量下降	南京003店	P00025	1.67 / 4	-58.3%	09-28 ~ 09-30	diagnosed
critical	销量上升	广州006店	P00017	6 / 3	100%	09-17 ~ 09-19	diagnosed

图 5-1 异常中心：自动发现的异常列表，按严重程度标记

6 根因分析

点击任一异常进入详情页，左侧为检测证据链（全部来自业务系统真实数据），右侧为原因分析：系统对缺货、供应链延迟、促销、竞品促销、天气、客诉、会员流失、临期、价格九类假设并行验证，仅当证据至少 2 条且方向相容时方可入选根因，按置信度排序取 Top3；证据不足时显式转人工而非硬给结论。

检测证据

全部来自业务系统真实数据

证据 1: BASELINE

```
{
  "baseline_days": 10,
  "baseline_median": 1,
  "baseline_std": 1
}
```

证据 2: OBSERVATION

```
{
  "observed": {
    "date": "2020-09-29",
    "observed_daily_avg": 0,
    "points": [
      {
        "date": "2020-09-29",
        "y": 0
      },
      {
        "date": "2020-09-30",
        "y": 6
      }
    ]
  }
}
```

原因分析

经过规则引擎推理得到根因候选

#1 证据不足，转人工分析 unknown

置信度 0%，贡献占比 0%

结论

该销量异常为销量骤降，实际销量为零，低于预期，降幅达百分之百；但现有证据不足，无法确定主要原因，建议转人工分析。

图 6-1 异常详情：证据链、根因 Top3（置信度与贡献占比）与结论叙述

7 补货与促销建议

决策层按根因匹配打法库生成建议卡：补货建议自动计算覆盖天数并向上取整到供应商最小起订量；促销建议自动校验毛利底线、折扣上限与预算上限。每

张建议卡均给出预估成本、预估收益、ROI 与销量恢复比例，供决策者直观比较；任何违反硬约束的方案在生成阶段即被丢弃，约束违反率为 0。




图 7-1 补货/促销建议：风险等级、ROI 与约束检查明细

8 授权执行与审批

执行层严格遵守“先建议、后执行”：低风险建议（如常规补货、10% 以内折扣）自动执行；超出 Agent 授权的高风险动作（折扣超过 10%、预算超过 1 万跨区域调拨等）一律生成审批单转人工，审批中心仅风控审批人（L3）可操作，通过后自动执行。




图 8-1 审批中心：高风险动作的人工确认与风险原因

9 执行记录与审计

每一步执行均有状态机管理（待执行→执行中→成功/失败→已补偿）；审计日志记录谁在什么时候对什么做了什么，通过 `trace_id` 可一键还原“发现→分析→建议→执行”完整链路，通过与拒绝同样留痕。




图 9-1 执行记录：状态机与业务单据关联




图 9-2 审计日志：支持 `trace_id` 过滤的全链路留痕

第三篇 治理与安全

10 权限矩阵与策略引擎

表 10-1 角色权限矩阵

角色	权限级	能做什么
风控审批人	L3	唯一可审批高风险动作
供应链计划员/会员运营/区域经理/店长/客服主管/总部运营	L2	低风险写入；店长仅限本店数据
Agent 服务身份	L2（硬上限）	低风险自动执行；任何高风险一律转审批
匿合/未授权	L0	只读，写入一律拒绝

表 10-2 风险规则（策略引擎消费机器可读规则库）

规则	处置
促销折扣超过 10%	必须审批
促销/触达预算超过 1 万	必须审批
任何价格变更	必须审批
跨区域库存调拨	必须审批
折扣超过 30% / 预算超过 10 万	直接拒绝（禁止动作）
白名单外动作	拒绝执行

11 写操作四保险

- **幂等：**相同 idempotency_key 重复提交重放首次结果，不重复下单；同键不同请求直接拒绝；
- **预演：**任何写入可预演，不落库也留审计痕；
- **审计：**成功、拒绝、失败均写审计日志，trace_id 贯穿全链路；
- **补偿：**补货、调拨、促销、工单均支持补偿回退，库存与单据同步恢复。

第四篇 部署与使用

12 快速启动

- 一键脚本：Windows 执行 `scripts\start.bat`，或 macOS/Linux 执行 `bash scripts/start.sh`；首次启动自动安装依赖并生成演示数据；
- 容器：`docker compose up --build`，适用于容器化环境；
- 手动：`pip install -r backend/requirements.txt` 后 `python scripts/generate.py` 再启动服务；
- 访问：打开 `http://127.0.0.1:8300`，按控制台右上角“运行 Agent”即可体验完整闭环。

13 在线预览与版本迭代

系统已部署至 GitHub Pages 提供只读在线预览；代码托管于 GitHub 仓库，每次提交推逃后 Actions 自动重建演示数据快照并发布，代码变更与版本迭代在 Commits 中完整可查。




图 13-1 GitHub Pages 在线只读预览（无后端环境自动降级为数据快照）

14 验收结果

表 14-1 全量验收指标（含真实 LLM 环境）

验收项	结果
测试套件（单元 + 集成 + Playwright 端到端）	42/42 全部通过
3 类注入异常召回率	100%（高于 90% 验收线）
根因 Top3 命中率	100%（高于 80% 验收线）
建议约束违反率	0
高风险审批合规率	100%
自动执行成功率	100%
LLM 叙述防编造校验	DeepSeek 实测通过，数字全部来自工具事实
GitHub Pages 在线预览	已上线并逐页验证

15 常见问题

- **Q：启动多久能用？** 首次启动需生成演示数据，约 1 分钟；后续启动直接运行。
- **Q：在线预览能操作吗？** 在线预览为只读快照；运行 Agent、审批、执行等写操作需本地启动后端。
- **Q：必须配置大模型吗？** 不需要。未配置 API Key 时自动使用离线模板叙述，全部功能不受影响；配置方式见 `.env.example`。
- **Q：如何在自己环境跑起来？** 复制仓库后按 README 启动即可；所有数据均为 Mock 生成（固定种子可重复），不依赖任何真实企业系统。